

Desarrollo de una Aplicación de IA Generativa para Imágenes del Curso de Dibujo Minero

RUBEN RONALD BAUTISTA HUILLCA Científico de datos

NATHALIA MERMA HUAMAN Científico de datos

Cusco, Perú, 2024

Indice

Introducción.....	3
Objetivo General	3
Objetivos Específicos.....	3
Problemática	4
Estado del Arte	4
Conditional Generative Adversarial Networks (CGAN).....	4
Wasserstein Generative Adversarial Networks (WGAN)	4
Metodología.....	5
Creación de la Base de Datos	5
Elección de Modelos	5
Entrenamiento y Mejora de los Modelos	5
Data Augmentation	6
Desarrollo de la Aplicación de Escritorio	6
Resultados	7
Comparación de Modelos	7
Análisis de Rendimiento	7
Conclusiones.....	8
Recomendaciones.....	8
Bibliografía.....	9
Glosario	9

Introducción

Este proyecto se ha desarrollado con el objetivo de crear una aplicación de inteligencia artificial (IA) para generar imágenes del curso de Dibujo Minero de la Escuela de Ingeniería de Minas de la Universidad Nacional San Antonio Abad del Cusco (UNSAAC). Para este fin, se han utilizado dos modelos de redes generativas adversariales: Conditional Generative Adversarial Networks (CGAN) y Wasserstein Generative Adversarial Networks (WGAN). La profesora encargada de recibir este proyecto es la docente del curso de Dibujo Minero.

Objetivo General

Desarrollar una aplicación de inteligencia artificial que permita la generación de imágenes de alta calidad para el curso de Dibujo Minero de la Escuela de Ingeniería de Minas de la Universidad Nacional San Antonio Abad del Cusco (UNSAAC).

Objetivos Específicos

- **Implementar** modelos CGAN y WGAN para la generación de imágenes.
- **Desarrollar** una base de datos estructurada con imágenes del curso de Dibujo Minero.
- **Evaluar** el rendimiento de los modelos mediante métricas de calidad de imagen.
- **Crear** una interfaz de usuario intuitiva para la aplicación de escritorio.
- **Aplicar** técnicas de Data Augmentation para mejorar el rendimiento del modelo.
- **Facilitar** el acceso a recursos visuales para estudiantes y profesores del curso.
- **Innovar** en la enseñanza del Dibujo Minero mediante el uso de tecnologías avanzadas.

Problemática

El curso de Dibujo Minero requiere una cantidad considerable de material visual específico que no siempre está disponible o es de difícil acceso. La generación manual de estos recursos puede ser laboriosa y costosa, además de presentar variaciones en calidad y consistencia. Este proyecto busca abordar estos problemas mediante el uso de IA para automatizar y estandarizar la creación de imágenes educativas.

El acceso limitado a material visual de calidad afecta negativamente la comprensión y el aprendizaje de los estudiantes. La falta de estandarización en los dibujos manuales puede llevar a interpretaciones erróneas y a una menor eficiencia en el proceso de enseñanza. La automatización con IA no solo soluciona estos problemas, sino que también permite la creación rápida y eficiente de imágenes específicas que se ajusten a las necesidades del curso.

Estado del Arte

Las Redes Generativas Adversariales (GANs) han revolucionado el campo de la generación de imágenes. CGANs, introducidas por Mirza y Osindero en 2014, son una extensión de las GANs tradicionales que permiten generar imágenes condicionadas por etiquetas. WGANs, propuestas por Arjovsky, Chintala y Bottou en 2017, introdujeron mejoras significativas en la estabilidad del entrenamiento y la calidad de las imágenes generadas. Ambas técnicas han demostrado ser efectivas en una variedad de aplicaciones, pero su uso en el ámbito educativo sigue siendo relativamente nuevo y poco explorado.

Conditional Generative Adversarial Networks (CGAN)

CGAN es una variación de las GANs que permite la generación de imágenes condicionadas a partir de ciertas etiquetas o información adicional. Esta capacidad es particularmente útil en un entorno educativo donde se necesitan imágenes específicas. La red generadora y la red discriminadora de una CGAN reciben tanto el vector de ruido como la etiqueta de la clase como entradas, lo que guía la generación de imágenes hacia un resultado deseado.

Wasserstein Generative Adversarial Networks (WGAN)

WGAN introduce un nuevo enfoque para entrenar GANs utilizando la distancia de Wasserstein como métrica de pérdida. Este enfoque mejora significativamente la estabilidad del entrenamiento y la calidad de las imágenes generadas. WGAN aborda algunos de los problemas más comunes de las GANs tradicionales, como el colapso de modos y la dificultad para ajustar los hiperparámetros.

Metodología

Creación de la Base de Datos

Recopilación

Se inició el proyecto recopilando una amplia gama de dibujos y esquemas utilizados en el curso de Dibujo Minero. Estos materiales fueron digitalizados y organizados en una base de datos estructurada. Cada imagen fue etiquetada con información relevante, como el tipo de dibujo, la técnica utilizada y el tema del contenido, para facilitar su uso en el entrenamiento de los modelos de IA.

Organización

La organización de la base de datos incluyó el etiquetado meticuloso de cada imagen para asegurar que los modelos de IA pudieran acceder y aprender de los datos de manera efectiva. Se utilizaron herramientas de gestión de datos para mantener la integridad y accesibilidad de la base de datos a lo largo del proyecto.

Elección de Modelos

CGAN

La elección de CGAN se debió a su capacidad para generar imágenes condicionadas. Este modelo se entrenó utilizando las etiquetas de la base de datos para producir imágenes que cumplieran con los requisitos específicos del curso de Dibujo Minero.

WGAN

WGAN fue seleccionado por su estabilidad en el entrenamiento y la calidad superior de las imágenes generadas. El modelo se ajustó para minimizar problemas comunes en las GANs tradicionales, como el colapso de modos y la oscilación en el proceso de entrenamiento.

Entrenamiento y Mejora de los Modelos

Entrenamiento Inicial

Se entrenaron ambos modelos utilizando la base de datos recopilada. El proceso de entrenamiento implicó el uso de potentes GPUs para acelerar los cálculos y mejorar la eficiencia del proceso.

Ajuste de Hiperparámetros

El ajuste de los hiperparámetros fue un proceso iterativo que involucró múltiples experimentos para encontrar la configuración óptima. Se ajustaron parámetros como la tasa de aprendizaje, el tamaño del lote y el número de capas en las redes generadora y discriminadora.

Evaluación

Se evaluó la calidad de las imágenes generadas utilizando métricas objetivas como el Frechet Inception Distance (FID) y el Structural Similarity Index (SSI). Además, se buscó la retroalimentación de expertos en el tema para asegurar que las imágenes cumplieran con los estándares del curso.

Data Augmentation

Técnicas Aplicadas

Para aumentar la diversidad del conjunto de datos y mejorar la capacidad de generalización del modelo, se aplicaron técnicas de Data Augmentation. Estas técnicas incluyeron:

- **Rotaciones:** Girar las imágenes a diferentes ángulos para crear nuevas variaciones.
- **Traslaciones:** Mover las imágenes a diferentes posiciones dentro del marco para simular diferentes puntos de vista.
- **Escalados:** Cambiar el tamaño de las imágenes para introducir variaciones en la escala.
- **Otras Transformaciones:** Incluir cambios en el brillo, contraste, y adición de ruido para crear un conjunto de datos más robusto.

Propósito

El propósito de estas técnicas es aumentar la cantidad de datos disponibles sin la necesidad de recopilar nuevas imágenes manualmente. Esto mejora la capacidad del modelo para generalizar y manejar una variedad de situaciones y condiciones en el entorno de aprendizaje.

Desarrollo de la Aplicación de Escritorio

Herramientas Utilizadas

El desarrollo de la aplicación de escritorio se realizó utilizando un entorno de desarrollo amigable para el usuario. Se emplearon tecnologías como Python y PyQt para crear una interfaz gráfica (GUI) que fuera intuitiva y fácil de usar.

Funcionalidades

La aplicación permite al usuario final generar imágenes del curso de Dibujo Minero simplemente ingresando las etiquetas o descripciones deseadas. Además, se incluyeron funcionalidades adicionales como la capacidad de guardar y exportar las imágenes generadas, así como opciones para ajustar parámetros específicos del modelo para obtener resultados personalizados.

Diseño de Interfaz

La interfaz de la aplicación fue diseñada para ser intuitiva y fácil de usar. Se llevaron a cabo pruebas de usabilidad con estudiantes y profesores para asegurar que la herramienta cumpliera con sus necesidades y expectativas. La GUI incluye menús y botones claros, así como tutoriales y ayudas visuales para guiar al usuario en el proceso de generación de imágenes.

Resultados

Los modelos CGAN y WGAN lograron generar imágenes de alta calidad, cada uno con sus ventajas específicas. CGAN demostró ser eficaz en la generación de imágenes específicas condicionadas a etiquetas, mientras que WGAN mostró una mayor estabilidad en el entrenamiento y una calidad superior en las imágenes generadas.

Comparación de Modelos

- **CGAN:**
 - Pros: Capacidad para generar imágenes condicionadas, flexibilidad en la especificación de parámetros.
 - Contras: Mayor sensibilidad a los ajustes de hiperparámetros, puede requerir más tiempo de ajuste.
- **WGAN:**
 - Pros: Estabilidad en el entrenamiento, calidad superior de las imágenes generadas.
 - Contras: Menor flexibilidad en la generación condicionada comparado con CGAN.

Análisis de Rendimiento

Se realizaron pruebas de rendimiento y se compararon las imágenes generadas con los dibujos originales del curso. Se utilizaron métricas como Frechet Inception Distance (FID) y Structural Similarity Index (SSI) para evaluar la similitud y calidad de las imágenes generadas. Además, se buscó la retroalimentación de expertos y usuarios finales para evaluar la utilidad y precisión de las imágenes generadas en un contexto educativo.

Conclusiones

Este proyecto representa un esfuerzo significativo para integrar la tecnología de IA en el entorno educativo de la UNSAAC, proporcionando una herramienta innovadora para el curso de Dibujo Minero. La aplicación desarrollada no solo mejora la experiencia de aprendizaje de los estudiantes, sino que también facilita el acceso a recursos visuales de alta calidad y estandarizados.

Recomendaciones

- **Implementar** una fase de validación con usuarios reales (estudiantes y profesores) para obtener retroalimentación y realizar mejoras en la aplicación.
- **Explorar** la inclusión de más modelos de IA para comparar su rendimiento y beneficios.
- **Desarrollar** módulos adicionales que permitan la personalización de las imágenes generadas según las necesidades específicas de los usuarios.

Bibliografía

- Mirza, M., & Osindero, S. (2014). Conditional Generative Adversarial Nets. arXiv preprint arXiv:1411.1784.
- Arjovsky, M., Chintala, S., & Bottou, L. (2017). Wasserstein GAN. arXiv preprint arXiv:1701.07875.
- Goodfellow, I., et al. (2014). Generative Adversarial Nets. Advances in neural information processing systems, 27.

Glosario

- **CGAN:** Redes Generativas Adversariales Condicionales, permiten la generación de imágenes basadas en etiquetas específicas.
- **WGAN:** Redes Generativas Adversariales de Wasserstein, mejoran la estabilidad del entrenamiento y la calidad de las imágenes generadas.
- **Data Augmentation:** Técnicas utilizadas para aumentar la diversidad del conjunto de datos mediante transformaciones de las imágenes existentes.
- **FID (Frechet Inception Distance):** Métrica utilizada para evaluar la similitud entre dos conjuntos de imágenes.
- **SSI (Structural Similarity Index):** Métrica utilizada para evaluar la calidad visual de las imágenes.